LLM AGENTS · НИУ ВШЭ · PROJECT PROPOSAL

Прогулка

Агенты строят пешие маршруты
по новому городу на каждый день

Роман Бекетов
@rbeketov

Ярослав Кузьмин
@yarikTri

Даниил Горнин
@dgornin

Иван Прыгунов
@juzu400

progulka.gornin.com · github.com/dgornin/progulka



Что делать на месте — самая долгая задача

Вся подготовка одной поездки 17 ч 42 мин

3 ч 54 мин

впечатления и экскурсии
22% · самая долгая

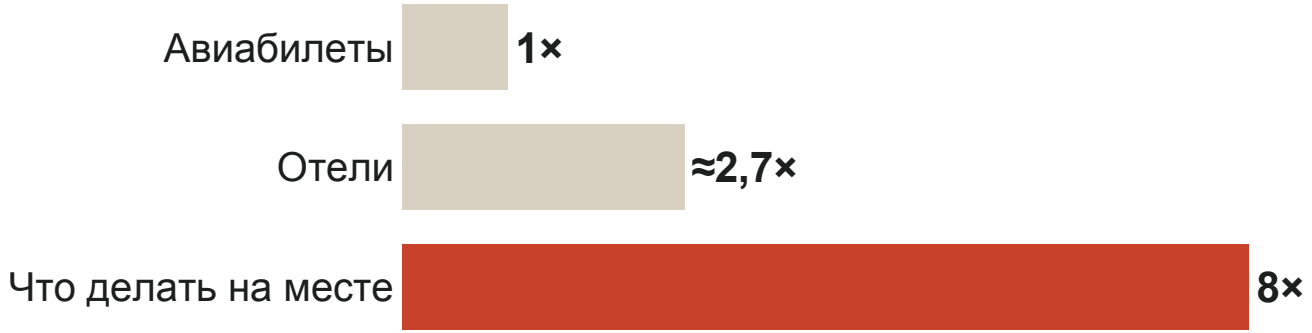
13 ч 48 мин

билеты · жильё · аренда авто · рестораны · и др.

78% · каждая задача короче 3 ч 54 мин

…и самая частая в поиске

запросов за 12 недель до поездки, в разах к авиабилетам



Go City × Talker Research, 2024: доли других задач не опубликованы; 13 ч 48 мин = 17 ч 42 мин − 3 ч 54 мин · Google, 2019: отели ≈2,7× = 8 / 3

Билеты и жильё решены, «куда сходить» — нет



69%
бронируют в день поиска

3 ч 54 мин · 22%
дольше любой другой задачи

Go City × Talker Research, 2024 · опрос Яндекс Путешествий, 2026

Вручную — семь шагов на каждый день



86% поездок — без готового тура: маршрут собирают сами

Туту, 2026: готовый тур — в 14% поездок

Каждый шаг — агенту, LLM или коду



агент · код · LLM + код

≈4 ч → 1–2 мин

поиск вручную опрос США → черновик поездки агентами + проверка по ссылкам

популярность — Wikidata и просмотры Википедии; условия TripAdvisor, Google и Yelp не дают отдавать их отзывы LLM · вручную — Go City × Talker Research, 2024, опрос в США: 3 ч 54 мин · агентами — наш eval: 4 поездки на 3–5 дней, 55–96 с, $0,03–0,05 за поездку

LLM — язык, агент — поиск, код — факты

LLM

свободный запрос — правилами не разобрать

«кофе и виды на воду, музеи не надо»

Агенты

поиск зависит от найденного

день 1 | день 2 | день 3

Код

нужна точность, а не язык

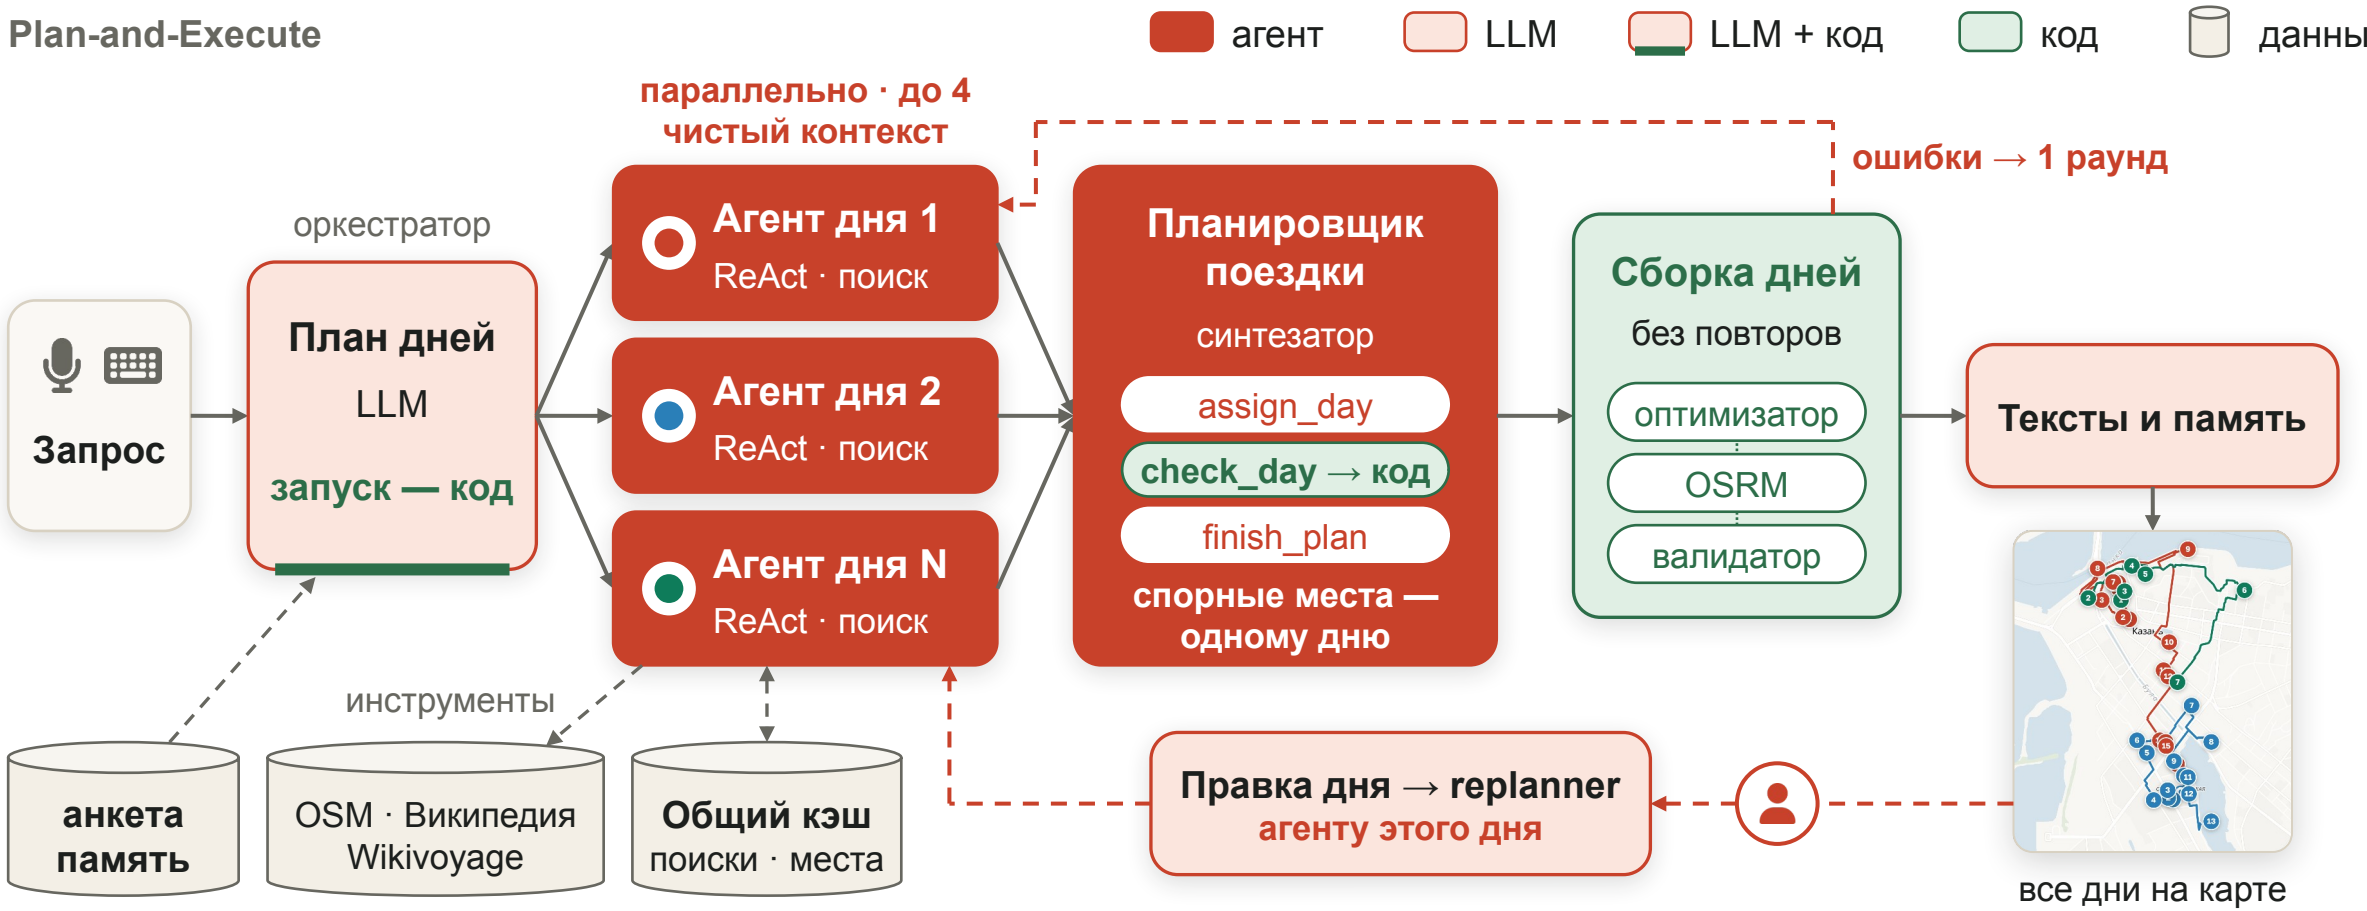
✓ часы | ✓ путь | ✓ повторы

0,6%

выполнимых планов у LLM-агента без проверки кодом

TravelPlanner (Xie et al., ICML 2024): GPT-4-Turbo + ReAct с инструментами

Агенты дней ищут, планировщик делит места



с планировщиком дни ровнее (худший день 58% от лучшего против 47%), +$0,01 и +19 с на поездку · 4 поездки

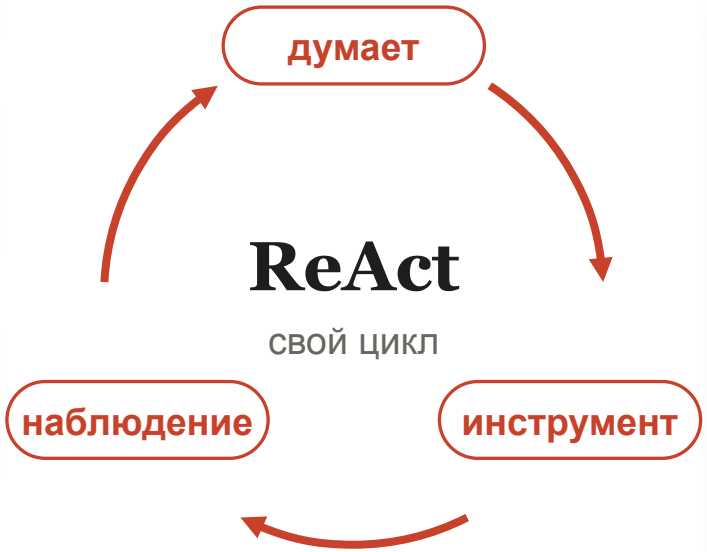
Агент дня не может выдумать место

7 инструментов
JSON Schema · + популярность

Заземление
только id из инструмента

Память
общий кэш · анкета · факты

Остановка
finish · 14 шагов · 150 с



● 1 · 12:02–13:02 · кафе ×

Tatar by tubetey

Кафе-музей татарской кухни находится в 90 метрах от Кремля, поэтому это удобное место для начала маршрута. Здесь можно познакомиться с татарской кухней, которая как раз вас интересует.

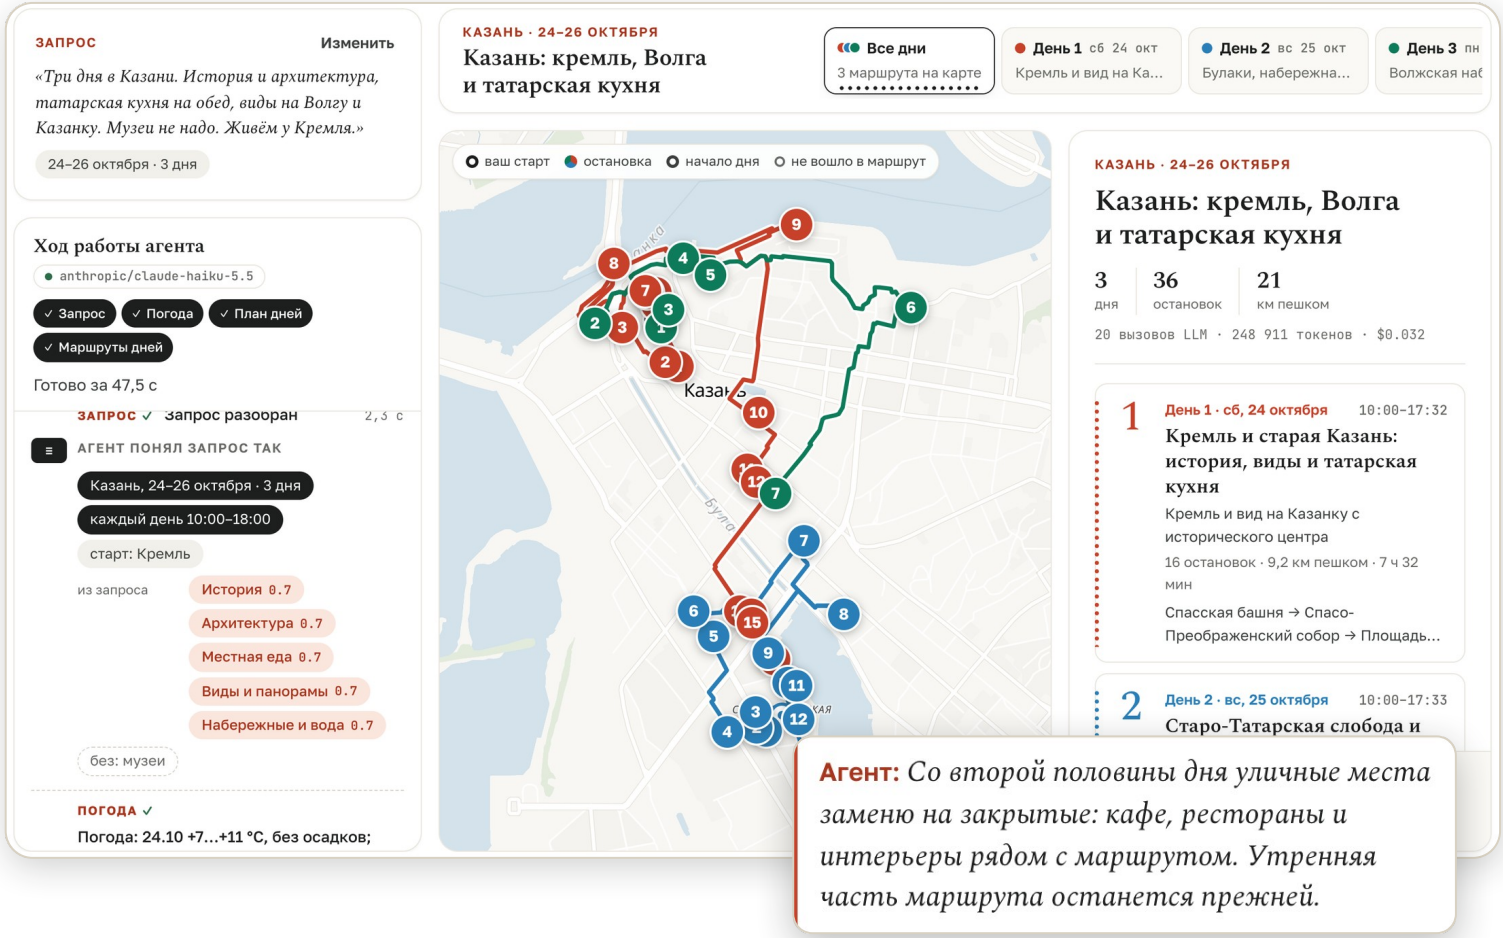
OpenStreetMap ↗ Яндекс Карты ↗
Google Maps ↗

Стек Claude Haiku 5.5 · OpenRouter · свой цикл на openai SDK · FastAPI + SQLite · Docker + Caddy

Демо

1. Голосом: 3 дня в Казани
2. Агенты дней — параллельно
3. Все дни на одной карте
4. Правка: «после обеда дождь» → агент запомнил

progulka.gornin.com



По маршруту из одного промпта часто не успеть

Одна модель — Claude Haiku 5.5 8 прогулок на день в 7 городах оба варианта проверяет один и тот же код	**Один промпт** модель просят один раз, без инструментов	**Агент** наша система: агенты с инструментами и код
Не успеть пешком на переход заложено меньше, чем идти пешком, + 5 мин	**13** переходов в 5 из 8 маршрутов	**0** переходов
Не успеть даже на транспорте меньше, чем метро или такси в лучшем случае	**7** переходов в 4 из 8 маршрутов	**0** переходов
Закрыто в момент визита по часам работы место в это время закрыто	**3**	**0**
Нашлось на карте конкретное место нашлось в OpenStreetMap по названию	**51%** 25 из 49 мест	**100%** по построению

Почему у агента 0 и 100%: время и путь считает код, часы — валидатор; места по построению только из источников

0 повторов мест
в 4 поездках на 3–5 дней

транспорт в лучшем случае — 10 мин на подход и ожидание + путь по улицам на 20 км/ч · переходы, финиши и «X или Y» не считаем местами · на маршрут: агент — 6 вызовов LLM, 57 тыс. токенов, $0,008, 28 с; один промпт — 1 вызов, 1,5 тыс. токенов, $0,0004, 23 с

Чем это лучше ChatGPT/Claude с поиском

	не успеть пешком	не успеть даже на транспорте	закрыто в визит	нашлось в OpenStreetMap	токенов на маршрут	$ за маршрут	время
Наш агент Haiku 5.5 · инструменты · код	**0** 0/8 маршрутов	**0** 0/8 маршрутов	**0**	**100%** 77 из 77 мест	**57 тыс.**	**$0,008**	**28 с**
Один промпт та же модель, без инструментов	**13** 5/8 маршрутов	**7** 4/8 маршрутов	**3**	**51%** 25 из 49 мест	**1,5 тыс.**	**$0,0004**	**23 с**
Чат + веб-поиск та же модель, Haiku 5.5	**21** 8/8 маршрутов	**21** 8/8 маршрутов	**2**	**87%** 34 из 39 мест	**45 тыс.**	**$0,044**	**12 с**
Чат + веб-поиск Claude Sonnet 5.5 · 5 маршрутов	**9** 4/5 маршрутов	**7** 4/5 маршрутов	**3**	**86%** 25 из 29 мест	**74 тыс.**	**$0,26**	**64 с**

0 против 21

переходов, где не успеть даже на метро или такси: агент и та же модель с поиском
Sonnet с поиском — 7, в 4 из 5 маршрутов

почти в 6 раз

дешевле, хотя токенов на 27% больше (57 тыс. против 45 тыс.): источники бесплатные, а веб-поиск платный
Sonnet с поиском — в 35 раз дороже

Честно

чат места не выдумывает: не нашлись в основном составные названия.
Он быстрее (12 с против 28 с) и берёт более известные места

не успеть пешком — на переход заложено меньше, чем идти пешком, + 5 мин · даже на транспорте — меньше, чем 10 мин на подход и ожидание + путь по улицам на 20 км/ч · нашлось — конкретное место нашлось в OpenStreetMap по названию; переходы, финиши и «X или Y» не считаем · токены — все вызовы LLM на маршрут; $ — с платой за поиск · 8 однодневных прогулок, Sonnet — 5, цена сравнивается на тех же 5 · ответ чата в JSON переводит наша модель · время чата — только ответ

К финалу — глубина, а не новые кнопки

К финалу

- Абляция: один агент на поездку против агента на день
  + улучшить планировщик: время, баланс дней
- LangGraph против своего цикла
- LLM-as-judge: персонализация и память
- RAG по путеводителям
- Трассировка агентов

Не делаем

- бронь и оплату
- ролевой чат агентов
- LLM-критика поверх валидатора

Спасибо!

Вопросы?

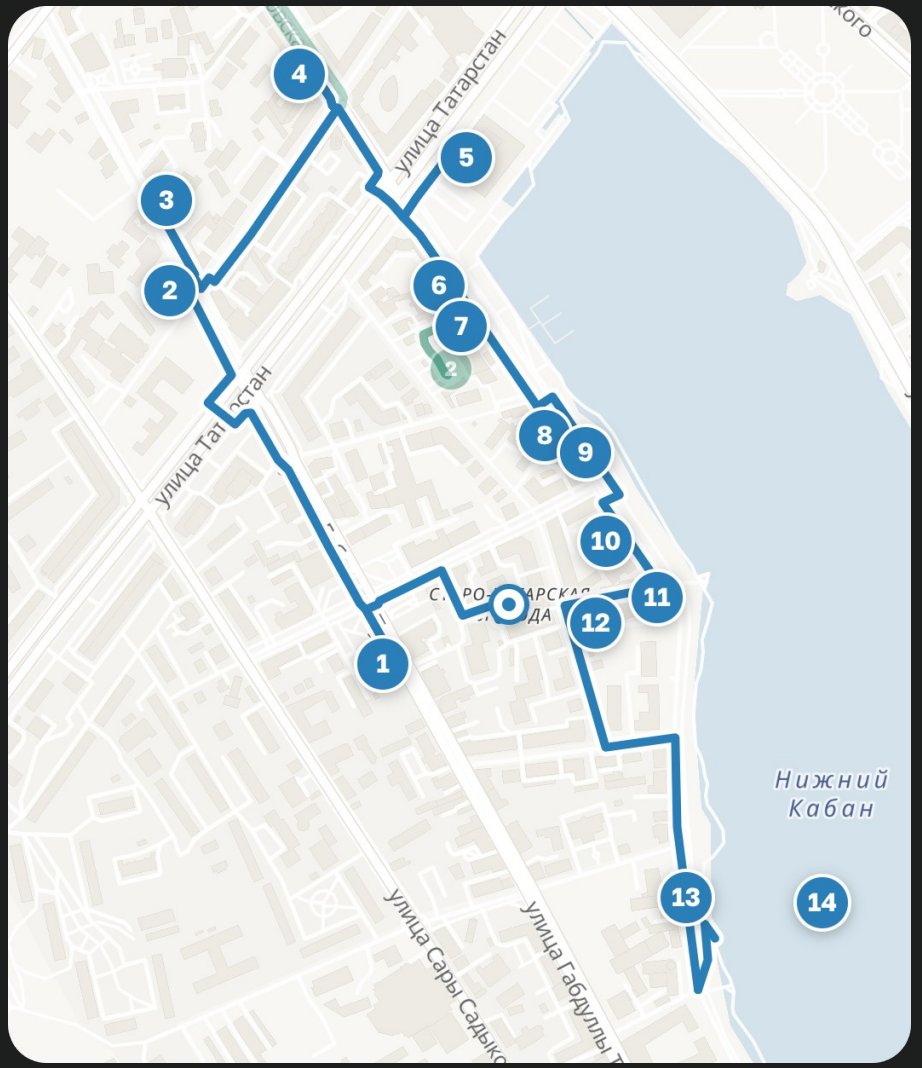
progulka.gornin.com

живая версия

github.com/dgornin/progulka

репозиторий

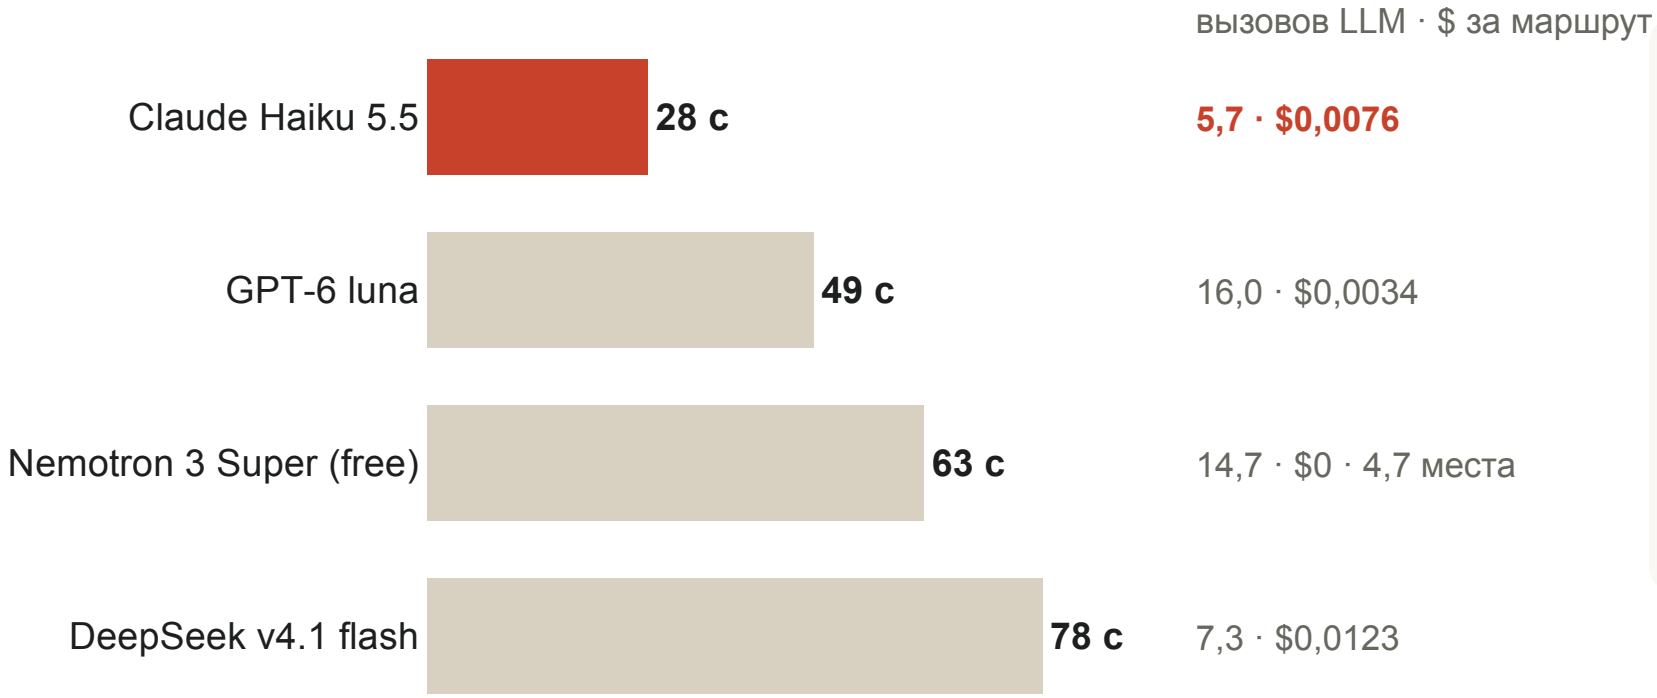
демо-аккаунт — на странице входа



Claude Haiku 5.5: меньше шагов, быстрее всех

Секунд на маршрут

3 одинаковых запроса, полный пайплайн



7 ролей LLM
один .env

голос
qwen3.8-omni-flash

Средние по 3 запросам (СПб, Казань, Париж) — ориентир, а не статистика · Haiku 5.5 — прогон с сигналом популярности, остальные — до него